

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Bases de Datos II

Semestre I – 2026



INFORME FINAL

Integrantes:

Chicalán Marroquín, Andrés Rafael - 21534

Yee Vidal, María José - 231193

De León García, Osman Emanuel - 23428

Consultoría de Minería de Datos para SmartStay Advisors

Informe General de Resultados — CC3074 Minería de Datos, Semestre I 2026

Grupo #8 | Osman Emanuel de León García (23428) · María José Yee Vidal (231193) ·
Andrés Rafael Chivalán Marroquín (21534)

1. Contexto y Objetivo de la Consultoría

SmartStay Advisors es una firma intermediaria que facilita la búsqueda y selección de propiedades en Airbnb para clientes corporativos y particulares. Su modelo operativo descansa en la capacidad de analizar la oferta disponible y proponer propiedades que optimicen la relación precio-calidad-disponibilidad. Airbnb, a su vez, ofrece incentivos económicos a SmartStay cuando logra incrementar la ocupación de propiedades con bajo desempeño.

En este marco, la empresa solicitó el desarrollo de un sistema de modelos de minería de datos orientados a cuatro objetivos estratégicos: estimar precios competitivos, identificar propiedades con baja ocupación, comprender los factores que influyen en la ocupación y los ingresos, y diseñar estrategias basadas en datos para aumentar la rentabilidad. El presente informe consolida los resultados de todas las fases de la consultoría, desde el análisis exploratorio hasta la implementación y comparación de modelos de aprendizaje automático supervisado.

2. Comprensión del Mercado: Análisis Exploratorio y Segmentación

El punto de partida fue el conjunto de datos listings.RData, que contiene 171,748 observaciones de alojamientos de Airbnb con 80 variables que describen características del anuncio, del anfitrión, de la ubicación y de las evaluaciones de los usuarios. El primer hallazgo crítico fue que la variable objetivo price presenta un 55.6% de valores faltantes, correspondientes a propiedades inactivas que no aportan información predictiva válida. Tras eliminar registros sin precio, observaciones con valores faltantes en variables estructurales clave (bedrooms, bathrooms, beds) y valores extremos mediante un criterio conservador de $3 \times \text{IQR}$, el dataset operativo se redujo a aproximadamente 71,690 registros con precios entre \$8 y \$944 USD por noche.

La distribución del precio original presenta un sesgo positivo pronunciado, con la mayoría de propiedades concentradas en rangos bajos y una cola derecha extendida. La transformación

logarítmica de price produce una distribución aproximadamente normal, validada mediante el estadístico de Shapiro-Wilk más cercano a 1, lo que justifica su uso como variable respuesta en los modelos de regresión lineal de la primera fase.

El análisis de correlación revela que las variables estructurales del inmueble —accommodates, bedrooms, bathrooms y beds— son los predictores con mayor correlación positiva con el precio, aunque exhiben alta multicolinealidad entre sí al medir esencialmente la misma dimensión: el tamaño de la propiedad. Las variables de disponibilidad (availability_365) y de reseñas (number_of_reviews, review_scores_rating) muestran correlaciones débiles pero estadísticamente significativas con el precio.

Para entender la heterogeneidad estructural del mercado se aplicó clustering K-means sobre las variables estandarizadas, determinando $k=4$ como número óptimo mediante el método del codo. Los cuatro segmentos identificados corresponden a: propiedades grandes y premium con alta capacidad y precio mediano de \$317; alojamientos compactos económicos con pocas reseñas y precio mediano de \$132; alojamientos estándar de alta actividad con precio mediano de \$140; y propiedades con alta disponibilidad anual y menor demanda con precio mediano de \$148. Esta segmentación evidencia que el mercado no es homogéneo y que la estrategia de precios de SmartStay debe diferenciarse según el perfil de la propiedad.

3. Modelos de Regresión Lineal: Estableciendo una Línea Base

Con el dataset final de 60,343 observaciones divididas en 80% entrenamiento y 20% prueba (semilla fija `set.seed(42)`), se construyeron cuatro modelos de regresión lineal usando `log_price` como variable respuesta. El modelo univariado con `accommodates` como único predictor establece la línea base con un R^2 de aproximadamente 0.25, confirmando que la capacidad de la propiedad es el predictor individual más fuerte pero insuficiente por sí solo.

El modelo múltiple con todas las variables numéricas disponibles mejora sustancialmente el R^2 , pero el análisis de VIF revela multicolinealidad severa entre las variables de tamaño. El modelo depurado, que elimina `beds` y `bedrooms` por redundancia con `accommodates` y `bathrooms`, logra $R^2=0.4096$ y $RMSE=0.5172$ en prueba con coeficientes estables e interpretables. El modelo LASSO, aplicado como técnica de regularización L1, produce resultados prácticamente equivalentes ($R^2=0.4094$), confirmando que la selección automática de variables no aporta mejora significativa cuando ya se controló la multicolinealidad manualmente. El modelo depurado fue seleccionado como referencia por su mayor interpretabilidad y robustez.

4. Modelos No Lineales: Árboles de Decisión y Random Forest

El Laboratorio 4 introdujo modelos no lineales manteniendo exactamente el mismo split 80/20 y semilla del Laboratorio 3, lo que permite comparación directa. El árbol de regresión con `rpart` y `cp=0.001`, usando `log_price` como respuesta, captura relaciones jerárquicas complejas que la regresión lineal no puede modelar. El modelo base alcanza $R^2=0.5013$, $RMSE=0.4753$ y $MAE=0.3721$ en prueba, lo que representa una mejora notable respecto al modelo lineal depurado.

El tuning del hiperparámetro `maxdepth` revela un patrón claro: el R^2 en prueba aumenta progresivamente hasta la profundidad 12 ($R^2=0.5328$, $RMSE=0.4601$), y se degrada ligeramente a profundidad 20, evidenciando sobreajuste. El modelo óptimo con `maxdepth=12` equilibra sesgo y varianza de manera adecuada. El modelo de Random Forest, implementado como extensión del Laboratorio 4, supera al árbol individual al reducir la varianza mediante el ensamble de múltiples árboles, aunque a mayor costo computacional.

Una diferencia metodológica importante: los Laboratorios 3 y 4 utilizaron `log_price` como variable respuesta con partición 80/20 y `set.seed(42)`. A partir del Laboratorio 5, la consultoría estandariza el uso de `price` directo con partición 70/30 y `set.seed(123)`, lo que hace que las métricas de ambos grupos no sean comparables en magnitud. Esta decisión se justificó por la necesidad de trabajar directamente con el precio en escala original para facilitar la interpretación de negocio.

5. Modelos Probabilísticos: Naive Bayes

El Laboratorio 5 introdujo Naive Bayes tanto para regresión como para clasificación, bajo las nuevas condiciones estandarizadas (70/30, `set.seed(123)`, `price` directo). La variable categórica `price_cat` fue construida dividiendo el precio en terciles, generando tres clases aproximadamente balanceadas: barata, media y cara, con distribución cercana a 33% por categoría.

Para regresión, Naive Bayes resultó inadecuado: $RMSE=2,816.22$, $MAE=957.95$ y $R^2=0.0028$, prácticamente indistinguible de predecir la media constante. Este resultado era esperado dado que el algoritmo asume independencia entre predictores y distribuciones gaussianas para variables continuas, supuestos violados en este dataset. Para clasificación triclase, Naive Bayes con `usekernel=TRUE` alcanzó una accuracy cercana al 90% en validación cruzada de 5 folds, resultado que debe interpretarse con cautela ya que el esquema de CV puede inflar la estimación respecto a la evaluación directa en el conjunto de prueba.

6. Modelos Basados en Distancia: K Nearest Neighbors

El Laboratorio 6 implementó KNN para regresión y clasificación. Para regresión, el modelo con `k=7` (normalización min-max) obtuvo $RMSE=2,516.13$, $MAE=331.42$ y $R^2=0.157$ en

prueba, con el tuning mediante CV de 5 folds seleccionando también $k=7$ como óptimo sin mejora adicional. Este fue el mejor modelo de regresión hasta ese punto entre los comparables, siendo el único con R^2 positivo y significativo frente a Naive Bayes.

Para clasificación, KNN con $k=15$ (seleccionado mediante CV) alcanzó $\text{accuracy}=0.6019$ y $\text{Kappa}=0.4026$. El modelo muestra el patrón consistente observado en todos los algoritmos: mejor desempeño en las clases extremas (barata y cara) y mayor dificultad en la clase media, cuya zona de transición genera solapamiento inherente en el espacio de características.

7. Clasificación con Probabilidades: Regresión Logística

El Laboratorio 7 introdujo regresión logística para clasificación binaria, modelando la probabilidad de que una propiedad pertenezca a la categoría cara. Todas las variables predictoras resultaron estadísticamente significativas ($p<0.05$), con *bathrooms*, *review_scores_rating* y *accommodates* como las de mayor impacto positivo, mientras *number_of_reviews* y *availability_365* mostraron relación negativa con la categoría cara. El análisis de VIF confirmó ausencia de multicolinealidad severa (todos los valores por debajo de 5).

El modelo alcanzó $\text{accuracy}=0.778$ y $\text{Kappa}=0.475$ en prueba, con $\text{AUC}=0.8293$ —indicativo de excelente capacidad discriminativa. El análisis de sobreajuste mostró diferencias mínimas entre train (0.7798) y test (0.7780), confirmando generalización adecuada. Este modelo, al ser binario, no es directamente comparable con los modelos triclase en términos de *accuracy*, pero es el más informativo para decisiones específicas sobre propiedades premium.

8. Máquinas Vectoriales de Soporte: Clasificación y Regresión

El Laboratorio 8 evaluó cuatro configuraciones de SVM para clasificación triclase bajo las condiciones estandarizadas. El kernel RBF con $C=1$ y $\text{gamma}=0.1$ obtuvo el mejor desempeño: $\text{accuracy}=0.6027$ y $\text{Kappa}=0.4037$ en prueba. La comparación de *accuracy* train vs. test revela ausencia de sobreajuste en todos los modelos (diferencias menores a 0.006), aunque el desempeño general sugiere subajuste estructural —especialmente visible en la clase media con sensibilidad máxima de 0.421.

Para regresión, el SVR con kernel RBF fue tuneado automáticamente mediante validación cruzada de 10 pliegues, seleccionando $C=10$, $\text{gamma}=0.5$, $\text{epsilon}=0.01$. El modelo final reportó $\text{RMSE}=2,738.14$, $\text{MAE}=288.82$ y $R^2=-0.001$ en prueba, lo que indica que el modelo no captura la varianza del precio continuo y su capacidad predictiva es equivalente a predecir la media constante. Este resultado, junto con el de Naive Bayes, confirma que la alta dispersión y los valores extremos del precio representan un obstáculo significativo para los modelos que no incorporan estructuras no lineales complejas.

9. Redes Neuronales Artificiales: Clasificación y Regresión

El Laboratorio 9 implementó redes neuronales feedforward con el paquete nnet, aplicando las mismas condiciones experimentales de los Laboratorios anteriores. Para clasificación se evaluaron dos topologías: una red superficial ($9 \rightarrow 10 \rightarrow 3$, $\text{decay}=0.01$) y una red ancha ($9 \rightarrow 25 \rightarrow 3$, $\text{decay}=0.001$). La red más ancha alcanzó $\text{accuracy}=0.618$ y $\text{Kappa}=0.4267$, superando a todos los modelos de clasificación triclase evaluados previamente. El tuning mediante validación cruzada de 3 pliegues sobre una grilla de tamaños y valores de decay produjo un modelo con $\text{accuracy}=0.6168$ y diferencia Train-Test de apenas 0.0015, confirmando excelente balance entre capacidad y generalización.

Para regresión, las dos topologías evaluadas —RNA 1 ($9 \rightarrow 10 \rightarrow 3$, $\text{decay}=0.01$) y RNA 2 ($9 \rightarrow 25 \rightarrow 3$, $\text{decay}=0.001$)— representaron un salto cualitativo respecto a todos los modelos anteriores. RNA 2 obtuvo $\text{RMSE}=2,308.32$, $\text{MAE}=374.29$ y $R^2=0.2887$ en prueba, siendo el primer modelo en superar $R^2=0.25$ bajo las condiciones estandarizadas. El tuning automático seleccionó una configuración con $\text{RMSE}=2,372.17$ y $R^2=0.2491$, ligeramente inferior al modelo base RNA 2, lo que indica que la configuración manual con mayor número de neuronas y menor regularización ya capturaba adecuadamente las relaciones no lineales del problema.

10. Comparación Final de Modelos

Clasificación (condiciones comparables: `set.seed(123)`, 70/30, `price_cat` triclase)

Modelo	Acc_Test	Kappa	Δ Train-Test	Diagnóstico
RNA Tuneada ($9 \rightarrow 25 \rightarrow 3$)	0.6168	0.4249	+0.0015	Buen ajuste
RNA Modelo 2 ($9 \rightarrow 25 \rightarrow 3$)	0.6180	0.4267	-	Buen ajuste
Random Forest	0.6377	0.4563	+0.3505	Sobreajuste severo
SVM RBF $C=1$ $g=0.1$	0.6027	0.4037	+0.0059	Buen ajuste
KNN $k=15$	0.6019	0.4026	-	Buen ajuste
Naive Bayes (CV-5)	~ 0.9086	~ 0.86	-	Requiere validación adicional

Nota: Regresión Logística ($\text{Acc}=0.778$) no es comparable directamente por ser clasificación binaria.

Regresión (condiciones comparables: set.seed(123), 70/30, price directo)

Modelo	RMSE_Test	MAE_Test	R ² _Test
RNA Modelo 2 (9→25→3)	2,308.32	374.29	0.2887
RNA Tuneada	2,372.17	334.55	0.2491
KNN k=7	2,516.13	331.42	0.1570
SVR tuneado	2,738.14	288.82	-0.001
Naive Bayes	2,816.22	957.95	0.0028

Nota: Modelos de Laboratorios 3-4 (log_price, 80/20, set.seed(42)) no son directamente comparables en magnitud.

11. Análisis de Sobreajuste

El único modelo con sobreajuste severo es Random Forest, con una diferencia Train–Test de 0.35 puntos de accuracy (Train=0.988, Test=0.638), evidenciando memorización del conjunto de entrenamiento sin generalización adecuada. Todos los modelos SVM y RNA mantienen diferencias menores a 0.006, lo que constituye el estándar de referencia para buen ajuste en este dataset. La Regresión Logística también muestra diferencia mínima (0.002). Para clasificación, la métrica clave de diagnóstico es la diferencia de accuracy train vs. test: valores superiores a 0.05 indican sobreajuste; valores negativos o con accuracy en prueba inferior a 0.55 sugieren subajuste.

12. Conclusiones y Recomendaciones para SmartStay Advisors

Los modelos evaluados a lo largo de esta consultoría convergen en un diagnóstico compartido: las nueve variables predictoras disponibles tienen capacidad discriminativa moderada pero insuficiente para modelar con alta precisión el precio de propiedades Airbnb, independientemente del algoritmo. El precio en este mercado está fuertemente influenciado por factores no capturados en el dataset —localización geográfica precisa, tipo de propiedad, amenidades, fotografías, calidad del anfitrión— cuya incorporación mejoraría sustancialmente el desempeño predictivo.

Para clasificación de categoría de precio, el modelo recomendado para producción es la RNA tuneada (9→25→3, decay=0.001), que combina el mejor accuracy triclase sin sobreajuste ($\Delta\text{Train–Test}=0.0015$). Random Forest, aunque con mayor accuracy bruta, es descartado por su sobreajuste severo. Para aplicaciones donde solo se requiere identificar propiedades

premium (cara vs. no cara), la Regresión Logística sigue siendo el modelo más confiable con AUC=0.83 y excelente interpretabilidad de coeficientes.

Para predicción continua del precio, la RNA Modelo 2 es el mejor modelo disponible ($R^2=0.2887$, RMSE=2,308), aunque un R^2 de 0.29 sigue siendo bajo para una aplicación de negocio crítica. Se recomienda incorporar en futuras iteraciones: variables de localización geográfica (barrio, distancia a puntos de interés), tipo de propiedad (room_type), número y tipo de amenidades, y aplicar una transformación logarítmica sobre el precio para regularizar su distribución —condición que beneficiaría especialmente a SVR y KNN, que son los más sensibles a valores extremos.

SmartStay Advisors puede aprovechar los modelos actuales como herramientas de priorización y segmentación —identificando rápidamente propiedades en la categoría correcta y estimando rangos de precio orientativos— mientras se enriquece el dataset con las variables adicionales necesarias para alcanzar un poder predictivo operacionalmente suficiente.